

globaleventprognosis

Phillip Ginter
Informatik (IN)
Hochschule Furtwangen
78120 Furtwangen, Deutschland
phillip.ginter@hs-furtwangen.de

Daniel Schönle
Informatik (IN)
Hochschule Furtwangen
78120 Furtwangen, Deutschland
daniel.schoenle@hs-furtwangen.de

Abstract—aaa

Index Terms—wikipedia, prognosis, global event

I. EINLEITUNG

Aufgabenstellung hier wiedergeben

- Was ist Wikipedia?
- Wie viele Artikel, Edits, Autoren hat Wikipedia?¹
- Ein Edit bzw. Update in Wikipedia wird durch ein neues Ereignis der realen Welt ausgelöst. Das kann eine Wahl, ein Unfall, politische Konflikte oder eine Sportveranstaltung sein [1].
- Aufgabenstellung
 - Für eine Entität (z. B. eine Person des öffentlichen Lebens) aus der Gesamtheit der Wikipedia-Edit-Events in "Echtzeit" Events der realen Welt ableiten.
 - Wir betrachten nur die Metadaten (Zeitstempel, Autor, ...) und nicht den Inhalt der Änderung Änderung (z. B. textuelle Änderung).
 - ...
- Wie sieht so ein Burst of Wikipedia-Edits aus 1?




Fig. 1: Donald Rumsfeld's Rücktritt führte zu einem Burst an Autoren, die einen Wikipedia-Edit vornahmen [1].

II. VERWANDTE ARBEITEN

A. Burst Detection

Generell

Kleinberg's burst detection algorithm

Online Burst Detection Over High Speed Short Text Streams

Event Detection with Burst Information Networks

¹<https://en.wikipedia.org/wiki/Wikipedia:Statistics>

Realtime Die Realtime-Burst Detection über mehrere Fenstergrößen ist für die Analyse von Datenströmen hilfreich. Die üblichen Burst-Detektionsverfahren sind für die Echtzeiterkennung nicht effektiv. Die Realtime-Burst Detection benötigt eine neue Burst-Erkennungsmethode, die die Berechnung reduziert, indem redundante Datenaktualisierungen vermieden werden. Dabei wird ein Ereignis bei seinem Auftreten daraufhin analysiert inwiefern die Ankunfts Häufigkeit und im Vergleich zur vorherigen Perioden ansteigt.

Efficient Elastic Burst Detection in Data Streams
[1]

III. STREAMING DATA

Das Ziel unserer Aufgabenstellung ist die Verarbeitung von Streaming-Daten. Die Streaming Data-Architektur von Psaltis [2] ist für diese Art von Problem konzipiert und bildet die Grundlage für unsere Architektur. Nach der Vorstellung der Streaming Data-Architektur von Psaltis, zeigen wir unsere eigene konkrete Umsetzung und vergleichen eingesetzten Technologien mit Alternativen.

A. Streaming Data-Architektur

- Wie sieht eine Streaming Data-Architektur aus bzw. aus welchen Komponenten besteht sie [2]?
- Ist eine Streaming Data-Architektur für unsere Aufgabenstellung sinnvoll?

B. Konkrete Implementierung unserer Streaming Data-Architektur

Die obigen vier Stufen der Streaming Data-Architektur von Psaltis [2] haben wir mit den folgenden konkreten Technologien besetzt, um die Aufgabenstellung aus dem vorhergehenden Kapitel zu erfüllen. In diesem Kapitel geht es um die Frage, wieso wir uns für konkrete Technologien entschieden haben und im nachfolgenden Kapitel stellen wir die Implementierungsdetails vor.

- *Collection tier.* Wikipedia ist unsere Datenquelle.
- *Messaging queuing tier.* Wir nutzen ein Kafka-System: Weshalb Kafka? Welche Features (Durable messaging, Different Messaging Systems, Scalability, Performance, Transaction Support, Security, ...) sind für uns von großer Relevanz? Oder soll Kafka ein eigenes Kapitel bekommen?

- *Analysis tier*: Esper: warum / welche Features sind für uns von Relevanz? Wie sieht die Ausgabe nach der Analyse aus?
- *Data access tier*: ???

IV. PROTOTYP

Zur Lösung der Aufgabenstellung haben wir einen lauffähigen Prototyp entwickelt, der die Machbarkeit demonstriert. Dafür haben wir die im vorhergehenden Kapitel genannten Technologien eingesetzt. Die Details zu den entstandenen Anwendungen stellen wir in diesem Kapitel vor.

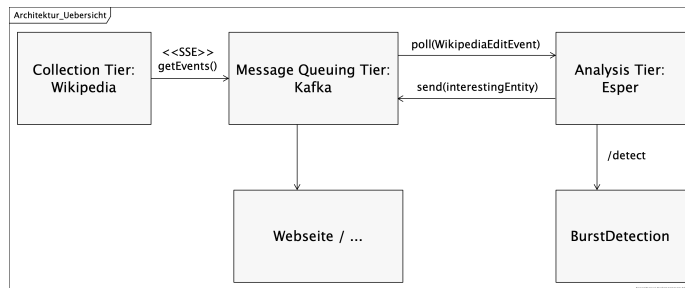


Fig. 2: Architekturübersicht

Abbildung 2 zeigt bisher nur eine sehr rudimentäre Übersicht und soll als Grundlage dienen. Die Verbindung zwischen Esper und Kafka muss noch genauer werden: Protokoll, senden von komplexen Events in neue Kafka-Topics.

A. Collection Tier: Wikipedia

- Was für Daten nutzen wir? WikipediaEditEvents
- Welche konkreten Daten hat ein WikipediaEditEvent?
- Wie sieht das System dahinter aus; wie verarbeitet Wikipedia die Daten: Kafka
- Was ist EventSource und was bringt es hier?

B. Implementierungsdetails zum Messaging queuing tier: Kafka

Im Messaging Queuing Tier setzen wir Apache Kafka in der Version 2.1 ein, um die Wikipedia-Events aus dem Collection Tier in unser eigenes Messaging-System zu überführen. In der Java-Anwendung werden die folgenden Schritte nacheinander ausgeführt:

- 1) *Kafka Initialisierung*. Den Host des Bootstrap-Servers setzen. Als Key- und Value-Serialisierer setzen wir jeweils den `StringSerializer` von Kafka ein. Das heißt, die Events werden als JSON-String in das Topic `wikiEdit` eingespeist. Zum Senden von Events erzeugen wir ein `Producer`-Objekt mit dem passenden Typ `Producer<String, String>`. TODO: Vor- und Nachteile für eine De-/Serialisierung von der eigenen `WikipediaEditEvent`-Klasse diskutieren
- 2) *Erzeugung eines EventHandlers*. Für das Empfangen von `EventSource`-Nachrichten nutzen wir die Java-Bibliothek `okhttp-eventsource`². Zur Verarbeitung

der Events `onOpen`, `onClose`, `onMessage`, `onComment` und `onError` muss das Interface `EventHandler` von `okhttp-eventsource` implementiert werden.

- 3) *Erzeugung und Starten einer EventSource*. Mit der `Stream-URI` der `Wikipedia-EventSource` und des implementierten `EventHandler`-Interfaces kann ein `EventSource`-Objekt erzeugt werden. Das Objekt dient dem Starten und Beenden eines `EventSource`-Streams.
- 4) *Beim Eintreffen eines Events, Senden einer Nachricht in ein Kafka-Topic*. Tritt ein `Wikipedia-Event` auf, wird die `onMessage`-Methode des implementierten `EventHandlers`-Interface aufgerufen. Einer der beiden Parameter enthält die Daten des aufgetretenen Events. Der Zugriff auf die als JSON-String codierte Nachricht erfolgt über die `getDate()`-Methode. Diese Daten sendet die Anwendung, über den zuvor erzeugten `Producer`, in das Kafka-Topic `wikiEdit`.

TODO: - Die Konfiguration von Kafka: Welche Topics gibt es? Partitions? Consumer Groups? Replication? Persistence? (oder alles schon im vorherigen Kapitel schreiben) - Vor- und Nachteile für eine De-/Serialisierung von der eigenen `WikipediaEditEvent`-Klasse diskutieren und der Einsatz von GSON?

C. Implementierungsdetails zum Analysis tier: Esper

In unserer Esper-Anwendung, die Teil des Analysis Tier ist, nutzen wir Esper in Version 7.1 als Complex Event Processing-Werkzeug. Zur Verarbeitung der Wikipedia-Events implementieren wir die folgenden Schritte:

Genaueres zu den erzeugten Expressions im nächsten Kapitel.

- 1) *Esper Initialisierung*. Die Initialisierung von Esper besteht
- 2) *Expression erzeugen*.
- 3) *UpdateListener implementieren*.
- 4) *Kafka initialisieren*.
- 5) *Kafka Consumer erzeugen und in Endlosschleife Events pollen*.
- 6) *Empfangene Events auswerten*.

V. ANWENDUNGSFÄLLE

Schauen, was man aus dem Paper bekommt: [1]

- 1) Voraussetzung: 2 oder mehr Autoren (die kein Bot sind) bearbeiten ein Ergebnis:

VI. PRAKTISCHE ANALYSE

- Wie sieht ein konkretes `Wikipedia-Edit-Event` aus / aus welchen Bestandteilen besteht es? siehe [1] Kapitel 2 Anfang
- Anhand von `Burst Detection`, wollen wir Events der realen Welt ableiten [3]
- Mit welchen Expressions decken wir welche Use Cases ab?

²<https://github.com/launchdarkly/okhttp-eventsource>

- Wie sind wir auf die Expressions gekommen? Nur durch ausprobieren?
- Reale Beispiele für "passende" Events
- Welche neuen "Komplexen Events" erzeugen wir?
- Reale Beispiele für komplexe Events
- Welche Ergebnisse liefert das System?
- Übersicht der Hierarchie von Ereignistypen: siehe EP_5_CEP_1pdf

VII. ERGEBNISSE

VIII. DISKUSSION

aa

IX. AUSBLICK

X. BEITRÄGE DER AUTOREN

Phillip und Daniel Schönle haben gleichermaßen zu dieser Arbeit beigetragen und sind Erstautoren.

REFERENCES

- [1] M. Georgescu, N. Kanhabua, D. Krause, W. Nejdl, and S. Siersdorfer, "Extracting event-related information from article updates in wikipedia," in *Advances in Information Retrieval*, P. Serdyukov, P. Braslavski, S. O. Kuznetsov, J. Kamps, S. Rüger, E. Agichtein, I. Segalovich, and E. Yilmaz, Eds. Berlin, Heidelberg: Springer Berlin Heidelberg, 2013, pp. 254–266.
- [2] A. Psaltis, *Streaming Data: Understanding the Real-time Pipeline*. Manning Publications, 2017.
- [3] Y. Zhu and D. Shasha, "Efficient elastic burst detection in data streams," in *Proceedings of the Ninth ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, ser. KDD '03. New York, NY, USA: ACM, 2003, pp. 336–345. [Online]. Available: <http://doi.acm.org/10.1145/956750.956789>